

状态特征函数 $f_k(x, i, y_i)$ 举例

我们考虑 一个简单的例子：

- 句子 `x = 自然`，长度 $n = 2$
- 标签集合 $\mathcal{L} = \{B, E\}$
- 只用一个模板 `U01:%x[0,0]`（取当前字）
- 状态特征集合（训练时枚举出来的）：`U01:自→B`、`U01:自→E`、`U01:然→B`、`U01:然→E`，这些状态集合实际上也是特征函数的下标几何。在程序实现中，通过python字典 型数据给每个特征函数 一个标签索引，外加一个全局的编号。

下面把 $f_k(x, i, y_i)$ 写成显式的指示函数，并数清有多少个。

一、状态特征函数

每个状态特征函数都是一个指示函数：

$$f_k(x, i, y_i) = \begin{cases} 1, & \text{第 } k \text{ 个特征在位置 } i \text{ 被触发, 且 } y_i \text{ 等于该特征对应的标签} \\ 0, & \text{否则} \end{cases} \quad (1)$$

注意： f_k 的下标 k 实际上对应一个具体的 (模板字符串, 标签) 组合，模版字符串标记它与当前位置的相对关系，比如该例子中只有一个模板字符串 `U01`，其中第一个位置的标签数据为 `自`，第二个位置的标签数据为 `然`。由于标签集合为 $\mathcal{L} = \{B, E\}$ ，因此我们总共将构造4个状态特征 函数。这些特征函数有三个自变量：字符串 x ；位置 i 注意应该大于等于1小于等于字符串长度； 标签 y_i 。

对 $x = \text{自然}$ ，位置 $i \in \{1, 2\}$ ，标签 $y_i \in \{B, E\}$ 。

特征函数1：特征函数编号为 $k = 1$ ，对应的(模板字符串, 标签) 组合为 `U01:自→B`

$$f_{U01:自 \rightarrow B}(x, i, y_i) = f_1(x, i, y_i) = \begin{cases} 1, & \text{若第 } i \text{ 个字符为自 且 } y_i = B \\ 0, & \text{否则} \end{cases} \quad (2)$$

根据模板 `U01:%x[0,0]` 在位置 i 触发第一个特征即 是指在第 i 个位置取到"自"，即 $i=1$ 。

特征函数 2：特征函数编号为 $k = 2$ ，对应的(模板字符串, 标签) 组合为 `U01:自→E`

$$f_{U01:自 \rightarrow E}(x, i, y_i) = f_2(x, i, y_i) = \begin{cases} 1, & \text{若第 } i \text{ 个字符为自 且 } y_i = E \\ 0, & \text{否则} \end{cases} \quad (3)$$

特征函数3：特征函数编号为 $k = 3$ ，对应的(模板字符串, 标签) 组合为 `U01:然→B`

$$f_{U01:然 \rightarrow B}(x, i, y_i) = f_3(x, i, y_i) = \begin{cases} 1, & \text{若第 } i \text{ 个字符为然 且 } y_i = B \\ 0, & \text{否则} \end{cases} \quad (4)$$

特征 函数5：特征函数编号为 $k = 4$ ，对应的(模板字符串, 标签) 组合为 `U01:然→E`

$$f_{U01:然 \rightarrow E}(x, i, y_i) f_4(x, i, y_i) = \begin{cases} 1, & \text{若第 } i \text{ 个字符为然 且 } y_i = E \\ 0, & \text{否则} \end{cases} \quad (5)$$

关键：因为 $x = \text{自然}$ 是固定的，"自"只会出现在 $i=1$ ，"然"只会出现在 $i=2$ ，所以每个 f_k 里位置 i 也被固定死了。这是短句 + 单模板的巧合，不是一般规律。

从上面 的分析可以看出，若语料中获取的状态集合中有 M 个元素，标签集合大小 L ，则状态特征函数个数 = $M \times L$ 。这里 M = 2（U01:自、U01:然），L = 2，所以 4 个。

二、状态分怎么用这些函数算？

$$\text{状态分} = \sum_{i=1}^2 \sum_{k=1}^4 w_k \cdot f_k(x, i, y_i) \tag{6}$$

以 $y = B E$ 为例：

i	y_i	触发哪个 f_k	权重
1	B	f_1 (U01:自→B)	$w_1 = 1.5$
1	B	f_2, f_3, f_4	0 (不触发)
2	E	f_4 (U01:然→E)	$w_4 = 1.2$
2	E	f_1, f_2, f_3	0 (不触发)

$$\text{状态分} = w_1 + w_4 = 1.5 + 1.2 = 2.7 \tag{7}$$

三、转移特征函数

转移特征 $g_l(y_{i-1}, y_i)$ 的形式：

$$g_l(y_{i-1}, y_i) = \begin{cases} 1, & \text{若 } (y_{i-1}, y_i) = \text{第 } l \text{ 种转移} \\ 0, & \text{否则} \end{cases} \tag{8}$$

标签对共 $L^2 = 4$ 种：

$$g_1 : (B, B), \quad g_2 : (B, E), \quad g_3 : (E, B), \quad g_4 : (E, E) \tag{9}$$

所以转移特征函数共 4 个，与句长、句子内容都无关（只和标签集合大小有关）。一般地，转移特征函数个数 = L^2 。

四、完整特征函数清单（本例）

状态特征（4 个）：

f1：U01:自→B

激活条件：i=1 且 y1=B

f2：U01:自→E

激活条件：i=1 且 y1=E

f3：U01:然→B

激活条件：i=2 且 y2=B

f4：U01:然→E

激活条件：i=2 且 y2=E

转移特征（4 个）：

g1：(B,B)

g2：(B,E)

g3：(E,B)

g4：(E,E)

总计 8 个特征函数